

Անգլիայի Պրեմիեր Լիգայի 2024–2025 մրցաշրջանի ֆուտբոլիստների տվյալների բազմաչափ վիճակագրական վերլուծություն

Ուսանող՝ Նելլի Մամիկոնյան | Առարկա՝ Բազմաչափ վիճակագրություն | Տարի՝ 2026

1. Ներածություն

Ժամանակակից սպորտային անալիտիկան լայնորեն հիմնվում է տվյալագիտության և վիճակագրական մեթոդների վրա: Ֆուտբոլում խաղացողների արդյունավետության գնահատումը բազմազան խնդիր է, քանի որ յուրաքանչյուր խաղացող բնութագրվում է բազմաթիվ փոխկապակցված ցուցանիշներով՝ կապված խաղաժամանակի, հարձակողական արդյունավետության, կարգապահության և ընդհանուր խաղային ակտիվության հետ: Նման տվյալների վերլուծությունը պահանջում է ոչ միայն առանձին փոփոխականների ուսումնասիրություն, այլև դրանց միջև առկա կառուցվածքային կապերի բացահայտում:

Բազմաչափ վիճակագրության մեթոդները հնարավորություն են տալիս ուսումնասիրել մեծ թվով փոխկապակցված փոփոխականներ, բացահայտել տվյալների ներքին կառուցվածքը, կառուցել կանխատեսիչ մոդելներ և իրականացնել դիտարկումների դասակարգում: Այդ պատճառով դրանք լայն կիրառություն են գտել ինչպես տնտեսագիտության և սոցիալական գիտությունների, այնպես էլ սպորտային տվյալների վերլուծության ոլորտներում:

Սույն աշխատանքի նպատակն է բազմաչափ վիճակագրական մեթոդների կիրառմամբ ուսումնասիրել Անգլիայի Պրեմիեր Լիգայի 2024–2025 մրցաշրջանի ֆուտբոլիստների տվյալները: Մասնավորապես իրականացվել են scatter plot վերլուծություն, բազմակի գծային ռեգրեսիա, փոփոխականների ընտրություն, գլխավոր բաղադրիչների վերլուծություն (PCA) և K-means կլաստերավորում: Ստացված արդյունքները հնարավորություն են տալիս գնահատել խաղացողների արդյունավետության վրա ազդող գործոնները և բացահայտել տվյալների բազայում առկա հիմնական օրինաչափությունները: Տվյալների աղբյուրը Kaggle հարթակում հրապարակված «Premier League 2024–2025 Data» տվյալների բազան է. <https://www.kaggle.com/datasets/furkanark/premier-league-2024-2025-data>

2. Տվյալների բազայի նկարագրություն

Վերլուծության համար օգտագործված տվյալների բազան բաղկացած է 574 դիտարկումներից և 25 փոփոխականներից: Փոփոխականների մի մասը նկարագրում է ֆուտբոլիստների հիմնական բնութագրերը (տարիք, թիմ, դիրք), իսկ մյուս մասը՝ նրանց մրցակցային արդյունավետությունը մրցաշրջանի ընթացքում:

Քանակական փոփոխականները կարելի է բաժանել մի քանի խմբերի.


- խաղաժամանակի ցուցանիշներ** (մասնակցությունների քանակ, մեկնարկների քանակ, խաղացած րոպեներ),
- հարձակողական արդյունավետության ցուցանիշներ** (գոլեր, գոլային փոխանցումներ, գոլային մասնակցություններ),
- 90 րոպեի հաշվով նորմավորված ցուցանիշներ**, որոնք հնարավորություն են տալիս համեմատել տարբեր խաղաժամանակ ունեցած ֆուտբոլիստներին,
- կարգապահական ցուցանիշներ** (դեղին և կարմիր քարտեր):

Տվյալների նախնական մշակումից հետո պարզվեց, որ բացակայող արժեքների քանակը չափազանց փոքր է և չի պահանջում լրացուցիչ մեթոդների կիրառում: Ուստի հետագա վերլուծությունը իրականացվել է տվյալների գրեթե ամբողջական բազայի վրա:

Տվյալների կառուցվածքը հարմար է բազմաչափ վիճակագրական մեթոդների կիրառման համար, քանի որ պարունակում է ինչպես ուժեղ փոխկապակցված փոփոխականներ, այնպես էլ տարբեր բնույթի ցուցանիշներ, որոնք կարող են արտացոլել խաղացողների արդյունավետության տարբեր կողմերը:

3. Scatter plot-ի վերլուծություն և բազմաչափ նորմալության գնահատում

Փոփոխականների միջև փոխկապակցվածությունների ուսումնասիրության նպատակով կառուցվել է Scatter Plot մատրից, որը թույլ է տալիս միաժամանակ դիտարկել ընտրված քանակական փոփոխականների զույգային կապերը և դրանց բաշխումները:



Նկար 1. Ընտրված փոփոխականների միջև զույգային կախվածությունների և բաշխումների գրաֆիկական ներկայացում

տվյալների բազան ամբողջությամբ չի բավարարում բազմաչափ նորմալ բաշխման ենթադրությանը:

4. Բացատրվող փոփոխականի ընտրություն

Ուեգրեսիոն վերլուծության համար որպես բացատրվող (response) փոփոխական ընտրվել է **Performance_G+A** ցուցանիշը, որը ներկայացնում է ֆուտբոլիստի ընդհանուր հարձակողական ներդրումը և հաշվարկվում է որպես խփած գոլերի և գոլային փոխանցումների գումար:

Այս փոփոխականի ընտրությունը պայմանավորված է նրանով, որ այն հանդիսանում է խաղացողի հարձակողական արդյունավետության առավել ամբողջական բնութագրիչներից մեկը: Ի տարբերություն միայն գոլերի կամ միայն փոխանցումների, տվյալ ցուցանիշը միաժամանակ հաշվի է առնում ինչպես գոլային իրացումները, այնպես էլ թիմակիցների գոլերին նպաստող գործողությունները:

5. Բազմակի գծային ռեգրեսիա

Performance_G+A փոփոխականի վրա տարբեր գործոնների ազդեցությունը գնահատելու նպատակով կառուցվել է բազմակի գծային ռեգրեսիայի մոդել: Մոդելում ներառվել են խաղացողի տարիքը, խաղաժամանակի ցուցանիշները, կարգապահական բնութագրերը և 90 րոպեի հաշվով հաշվարկված արդյունավետության ցուցանիշները:

Ստացված մոդելը վիճակագրորեն նշանակալի է (F-test, $p < 0.001$) և բնութագրվում է բարձր բացատրական կարողությամբ: Մոդելի արդյունքներով ստացվել է $R^2 = 0.774$ և Adjusted $R^2 = 0.769$, ինչը նշանակում է, որ հարձակողական արդյունավետության փոփոխականության շուրջ 77%-ը բացատրվում է մոդելում ներառված գործոններով:

Նկար 1-ում ներկայացված Scatter Plot մատրիցից երևում է, որ խաղաժամանակի և հարձակողական արդյունավետության որոշ ցուցանիշների միջև առկա են դրական կապեր: Մասնավորապես, ավելի մեծ խաղաժամանակ ունեցող ֆուտբոլիստները հակված են ունենալու ավելի մեծ գոլային և փոխանցումային արդյունավետություն:

Միաժամանակ, բազմաթիվ փոփոխականների բաշխումները բնութագրվում են արտահայտված ափսեորիայով և երկար աջ պոչերով: Հատկապես գոլերի, գոլային փոխանցումների և ընդհանուր գոլային մասնակցության փոփոխականներում դիտվում է մեծ քանակությամբ փոքր արժեքների կուտակում և համեմատաբար քիչ թվով մեծ արժեքներ:

Բազմաչափ նորմալ բաշխման դեպքում ակնկալվում են մոտավորապես էլիպսաձև և սիմետրիկ եզրային բաշխումներ: Սակայն դիտարկվող տվյալներում նման օրինաչափություններ հիմնականում չեն նկատվում: Հետևաբար, կարելի է եզրակացնել, որ

Գործակիցների գնահատականները ցույց են տալիս, որ խաղաժամանակի և հարձակողական արդյունավետության հետ կապված ցուցանիշները առավել մեծ ազդեցություն ունեն Performance_G+A փոփոխականի վրա, մինչդեռ որոշ կարգապահական բնութագրեր վիճակագրորեն նշանակալի ազդեցություն չեն ցուցաբերում: Միաժամանակ, condition number-ի բարձր արժեքը (8.83×10^5) մատնանշում է բազմակոլինեարության առկայություն, ինչը պայմանավորված է մի շարք փոխկապակցված բացատրող փոփոխականների միաժամանակ ներառմամբ մոդելում:

Ցուցիչ	Արժեք
Դիաադրկումների քանակ	573
R ²	0.774
Adjusted R ²	0.769
F-statistic	147.1
Prob(F-statistic)	9.25×10^{-171}
AIC	2695
BIC	2756

Աղյուսակ 1. Բազմակի գծային ռեգրեսիայի հիմնական արդյունքները

Ուստի հաջորդ փուլում իրականացվում է փոփոխականների ընտրություն՝ մոդելը պարզեցնելու, բազմակոլինեարությունը նվազեցնելու և առավել տեղեկատվական գործոնները առանձնացնելու նպատակով:

6. Փոփոխականների ընտրություն


Բազմակոլինեարության ազդեցությունը նվազեցնելու և առավել տեղեկատվական բացատրող փոփոխականները առանձնացնելու նպատակով կիրառվել է առաջընթաց (forward) փոփոխականների ընտրության մեթոդը: Արդյունքում ընտրվել են հետևյալ փոփոխականները՝ Playing_Time_Starts, Performance_PK, Performance_CrdY, Performance_CrdR և Per 90 Minutes_G+A-PK:

Ստացված ենթաբազմությունը պահպանել է մոդելի բացատրական կարողության մեծ մասը՝ միաժամանակ զգալիորեն նվազեցնելով մոդելի բարդությունը: Ընտրված փոփոխականները ցույց են տալիս, որ հարձակողական արդյունավետության վրա ազդում են ինչպես խաղային մասնակցությունը, այնպես էլ որոշ կարգապահական և արդյունավետության ցուցանիշներ:

7. Գլխավոր բաղադրիչների վերլուծություն (PCA)

Տվյալների չափողականությունը նվազեցնելու և փոփոխականների միջև առկա հիմնական կառուցվածքը բացահայտելու նպատակով իրականացվել է գլխավոր բաղադրիչների վերլուծություն (Principal Component Analysis, PCA):

Նկար 2-ում ներկայացված է կուտակային բացատրված տատանման (Cumulative Explained Variance) գրաֆիկը: Գրաֆիկից երևում է, որ առաջին գլխավոր բաղադրիչը բացատրում է ընդհանուր տատանման մոտ 42.7%-ը, իսկ առաջին երկու բաղադրիչները միասին՝ շուրջ 62.3%-ը: Կուտակային տատանումը գերազանցում է 80%-ը արդեն չորրորդ գլխավոր բաղադրիչի դեպքում:



Նկար 2. Կուտակային բացատրված տատանումը գլխավոր բաղադրիչների քանակից կախված


Այս արդյունքը ցույց է տալիս, որ սկզբնական մեծ թվով փոխկապակցված փոփոխականները կարելի է արդյունավետ կերպով ներկայացնել համեմատաբար փոքր թվով գլխավոր բաղադրիչների միջոցով՝ պահպանելով տվյալների հիմնական տեղեկատվությունը: Հետևաբար, PCA-ն հնարավորություն է տալիս նվազեցնել տվյալների չափողականությունը՝ առանց տեղեկատվության էական կորստի:

8. Կորելացիաների շրջանը

Կորելացիաների շրջանը թույլ է տալիս գնահատել փոփոխականների կապը առաջին երկու գլխավոր բաղադրիչների հետ: Վեկտորների ուղղությունը ցույց է տալիս փոփոխականների փոխկապակցվածությունը, իսկ շրջանագծի սահմանին մոտ գտնվելը՝ տվյալ բաղադրիչներով լավ ներկայացված լինելը:

Գրաֆիկից (նկ. 3) երևում է, որ **Performance_Gls**, **Performance_Ast** և **Performance_G+A** փոփոխականները գտնվում են նույն ուղղությամբ, ինչը վկայում է նրանց միջև ուժեղ դրական կապի մասին: Նմանատիպ վարքագիծ են ցուցաբերում նաև **Per 90 Minutes_Gls**, **Per 90 Minutes_Ast** և **Per 90 Minutes_G+A** փոփոխականները:


Մյուս կողմից, **Age** փոփոխականը գտնվում է կենտրոնին ավելի մոտ և ունի համեմատաբար թույլ կապ առաջին գլխավոր բաղադրիչի հետ: Ընդհանուր առմամբ, առաջին գլխավոր բաղադրիչը հիմնականում արտացոլում է խաղացողների հարձակողական արդյունավետությունը, իսկ երկրորդ բաղադրիչը տարբերակում է խաղաժամանակի և կարգապահական որոշ ցուցանիշների ազդեցությունը:



Նկար 3. Կորելացիաների շրջանը առաջին երկու գլխավոր բաղադրիչների հարթությունում

9. Դիտարկումների պրոյեկցիան առաջին երկու գլխավոր բաղադրիչների վրա

PCA մեթոդի կիրառման արդյունքում յուրաքանչյուր դիտարկում պրոյեկտվել է առաջին երկու գլխավոր բաղադրիչների հարթության վրա: Այս պրոյեկցիան թույլ է տալիս տեսողականորեն ուսումնասիրել տվյալների կառուցվածքը, բացահայտել հնարավոր արտասովոր դիտարկումները և գնահատել տվյալների տարածվածությունը նվազեցված չափողականության տարածությունում:



Նկար 4. Դիտարկումների պրոյեկցիան առաջին երկու գլխավոր բաղադրիչների հարթությունում

Գրաֆիկից (նկ. 4) երևում է, որ դիտարկումների մեծ մասը կենտրոնացած է կոորդինատային համակարգի կենտրոնական հատվածում, ինչը վկայում է խաղացողների մեծ մասի վիճակագրական բնութագրերի նմանության մասին: Միաժամանակ առկա են մի քանի հեռացված դիտարկումներ, որոնք կարելի է դիտարկել որպես արտասովոր (outlier) խաղացողներ՝ առանձնապես բարձր կամ ցածր ցուցանիշներով:


Առաջին գլխավոր բաղադրիչը (PC1) բացատրում է տվյալների ընդհանուր փոփոխականության 48.3%-ը, իսկ երկրորդ բաղադրիչը (PC2)՝ 21.8%-ը: Հետևաբար առաջին երկու բաղադրիչները միասին նկարագրում են տվյալների շուրջ 70% փոփոխականությունը, ինչը թույլ է տալիս պահպանել տվյալների հիմնական կառուցվածքը երկչափ ներկայացման մեջ:

10. K-means կլաստերացում


K-means կլաստերացումը կիրառվել է որպես լրացուցիչ բազմաչափ վերլուծության մեթոդ՝ ֆուտբոլիստներին ըստ վիճակագրական բնութագրերի խմբավորելու նպատակով: Քանի որ մեթոդը պահանջում է նախապես ընտրել կլաստերների քանակը, կիրառվել է Elbow մեթոդը:

Elbow մեթոդի գրաֆիկից (Նկ. 5) երևում է, որ WCSS ցուցանիշը զգալիորեն նվազում է մինչև $k=3$, որից հետո նվազման արագությունը դանդաղում է:

K-means կլաստերացման արդյունքները (Նկ. 6) ցույց են տալիս, որ ֆուտբոլիստները կարելի է



Նկար 6. K-means կլաստերների բաշխումը առաջին երկու գլխավոր բաղադրիչների հարթությունում



Նկար 5. Elbow մեթոդը K-means կլաստերների քանակի ընտրության համար

բաժանել երեք հիմնական խմբերի: Կլաստերները տարբերվում են խաղային ակտիվության, հարձակողական արդյունավետության և ընդհանուր արտադրողականության ցուցանիշներով: Թեև որոշ դիտարկումներ գտնվում են կլաստերների սահմանային հատվածներում, ընդհանուր պատկերը վկայում է տվյալներում որոշակի ներքին կառուցվածքի առկայության մասին: Ստացված արդյունքները լրացնում են

PCA վերլուծությունը՝ ցույց տալով, որ առաջին երկու գլխավոր բաղադրիչների տարածությունում հնարավոր է առանձնացնել տարբեր վիճակագրական պրոֆիլներով խաղացողների խմբեր:

Եզրակացություն

Սույն աշխատանքում իրականացվել է Անգլիայի Պրեմիեր Լիգայի 2024–2025 մրցաշրջանի ֆուտբոլիստների տվյալների բազմաչափ վիճակագրական վերլուծություն: Երկչափ Scatter Plot-ի ուսումնասիրությունը ցույց տվեց, որ տվյալներում առկա են մի շարք փոփոխապակցված փոփոխականներ, իսկ բազմաչափ նորմալության ենթադրությունը լիովին չի բավարարվում:

Բազմակի գծային ռեգրեսիայի արդյունքները ցույց տվեցին, որ ընտրված բացատրող փոփոխականները կարողանում են բացատրել Performance_G+A ցուցանիշի փոփոխականության զգալի մասը ($R^2 = 0.774$): Փոփոխականների ընտրության արդյունքում ստացվեց ավելի պարզ մոդել, որը պահպանեց հիմնական տեղեկատվությունը և թույլ տվեց առանձնացնել առավել կարևոր գործոնները:

PCA վերլուծությունը ցույց տվեց, որ տվյալների փոփոխականության մեծ մասը կարելի է նկարագրել համեմատաբար փոքր թվով գլխավոր բաղադրիչների միջոցով, իսկ կորելացիաների շրջանը հնարավորություն տվեց գնահատել փոփոխականների միջև առկա հիմնական կապերը: Դիտարկումների պրոյեկցիան առաջին երկու գլխավոր բաղադրիչների հարթությունում ցույց տվեց տվյալների ընդհանուր կառուցվածքը և որոշ առանձնացված դիտարկումների առկայությունը:

Որպես լրացուցիչ մեթոդ կիրառված K-means կլաստերացումը ցույց տվեց, որ ֆուտբոլիստները կարելի է բաժանել երեք հիմնական խմբերի՝ ըստ նրանց վիճակագրական բնութագրերի: Ընդհանուր առմամբ, կիրառված մեթոդները թույլ տվեցին բացահայտել տվյալների կառուցվածքային առանձնահատկությունները և ստանալ ֆուտբոլիստների արդյունավետության վերաբերյալ օգտակար վիճակագրական եզրակացություններ:

Հավելված A. Python կոդեր